

UNIVERSITÉ
CAEN
NORMANDIE

Apprentissage de Représentations Audio avec Transformers

De l'optimisation frugale à la génération multi-modale

Auteurs

CHEBANA Sofiene, BARRY Souleymane & RABOT Valentin

Université de Caen Normandie

Master 2 Informatique – Algorithmique & Systèmes Intelligents

1er octobre 2026

Table des matières

1 Introduction **1**

2 Ingénierie des Données et Frugalité Matérielle **1**

3 Architecture et Stabilisation de l'Apprentissage **1**

4 Pré-entraînement Auto-Supervisé (MAE) **2**

5 Reconnaissance Vocale (ASR) : Transfert et Compression **2**
5.1 Trajectoire d'Optimisation et Blank Collapse 2
5.2 Optimisation de l'Inférence (Pruning et Quantification) 3

6 Bonus 1 : Synthèse Vocale (TTS) et Post-Net **3**

7 Bonus 2 : Architecture Audio-LLM (Voxtral / ICLR 2026) **3**

8 Conclusion **3**

Résumé

Ce projet explore la conception, l'optimisation et le déploiement d'architectures basées sur les Transformers pour le traitement de la parole dans un environnement sous fortes contraintes matérielles (limite de 6 Go de VRAM). Nous détaillons l'implémentation d'un pipeline complet : de l'extraction de caractéristiques Log-Mel à l'inférence quantifiée pour la reconnaissance vocale (ASR). L'étude s'attache particulièrement à quantifier l'impact du pré-entraînement auto-supervisé (MAE) sur la trajectoire d'optimisation. Ce travail est complété par deux extensions génératives : un système de synthèse vocale (TTS) amélioré par un Post-Net résiduel, et une implémentation d'alignement inter-modal (Audio-LLM) inspirée de Voxtral (ICLR 2026).

1 Introduction

La conception de systèmes de reconnaissance automatique de la parole (ASR) requiert traditionnellement des ressources de calcul massives. L'objectif principal de ce projet est d'adopter une démarche frugale en explorant des méthodes de compression et de transfert d'apprentissage. En appliquant un pré-entraînement auto-supervisé (Masked Autoencoders) sur un encodeur Transformer léger, nous cherchons à extraire des représentations acoustiques robustes avant d'aborder la tâche complexe d'alignement temporel CTC.

2 Ingénierie des Données et Frugalité Matérielle

Afin de respecter les contraintes matérielles tout en maximisant l'efficacité de l'apprentissage sur nos corpus (Fluent Speech Commands et VoxPopuli), nous avons mis en place une architecture logicielle modulaire et optimisé le pipeline de données :

- **Mode Streaming et Collate Dynamique** : L'utilisation de la bibliothèque HuggingFace en mode streaming a permis d'extraire et de décoder les flux audio à la volée. Les spectrogrammes Log-Mel (64 filtres) sont calculés dynamiquement dans la fonction `collate_fn`, évitant la saturation de la RAM système.
- **Cropping Audio Strict** : La complexité spatio-temporelle de l'attention étant quadratique, les signaux ont été rigoureusement tronqués (10 secondes maximum pour l'ASR, 5 secondes pour le TTS) pour sécuriser l'empreinte VRAM.
- **Précision Mixte et Accumulation** : L'utilisation de `torch.amp.GradScaler` (Mixed Precision) couplée à une accumulation de gradients a permis de simuler de larges tailles de lots (batch size effectif de 128) tout en accélérant les calculs sur GPU.

3 Architecture et Stabilisation de l'Apprentissage

Notre architecture acoustique centrale repose sur un Audio Spectrogram Transformer (AST) volontairement sous-paramétré (environ 0.6M de paramètres) traitant des patchs temporels non-chevauchants.

Pour stabiliser l'apprentissage sur un faible volume de données, nous avons remplacé les optimiseurs standards par **AdamW**, intégrant une régularisation par *weight decay*. Le taux d'apprentissage a été dynamiquement adapté via un *OneCycleLR Scheduler* (avec une phase de warmup). Pour la tâche ASR, une approche par **Distillation de Connaissances** (architecture Étudiant-Professeur) a été implémentée pour guider notre modèle léger, couplée à une tokenisation BPE (Byte Pair Encoding) restreinte à 50 sous-mots pour limiter la dimension de la tête de prédiction.

4 Pré-entraînement Auto-Supervisé (MAE)

L'encodeur a été pré-entraîné sur une tâche de reconstruction auto-supervisée où 75% des patchs du spectrogramme d'entrée étaient masqués.

Trajectoire d'optimisation : L'entraînement sur 50 époques (5000 extraits) a révélé une dynamique d'apprentissage excellente, mesurée par l'erreur quadratique moyenne (MSE). Dès la première époque, le modèle affiche une perte moyenne de 0.3027. La régularisation permet ensuite une descente fluide et continue pour atteindre un niveau de reconstruction exceptionnel de 0.0048 à l'époque 50. Cette convergence prouve que l'encodeur assimile parfaitement la topologie acoustique locale (formants, harmoniques, silences) et constitue un socle d'initialisation optimal.

5 Reconnaissance Vocale (ASR) : Transfert et Compression

5.1 Trajectoire d'Optimisation et Blank Collapse

Le fine-tuning ASR a été évalué via la perte CTC (*Connectionist Temporal Classification*). Nous avons comparé la convergence d'un modèle initialisé aléatoirement (*From Scratch*) avec celle du modèle pré-entraîné (MAE), moyennés sur 5 *seeds*.

L'étude des logs d'entraînement sur 30 époques confirme l'avantage topologique de l'initialisation MAE. Le modèle *from scratch* débute avec une perte CTC moyenne de 9.9483 à la première époque, pour achever sa convergence à 3.1287 lors de la dernière époque. En revanche, le modèle pré-entraîné bénéficie d'un bien meilleur point de départ : sa perte initiale s'établit à 8.6999 et chute drastiquement dès les premières itérations.

Cependant, les deux trajectoires se heurtent à une limite structurelle : la perte de l'étudiant pré-entraîné se stabilise finalement autour de 4.2708. Cette divergence des minima locaux, bien que la descente de gradient soit saine dans les deux cas, se traduit par des résultats d'inférence identiques.

Modèle ASR	**Initialisation**	**WER (%)**	**Taille / Inférence**
Étudiant (Distillation)	Aléatoire (*From Scratch*)	99.01 ± 0.11	$\sim$ 0.6M / $\sim$ 1ms
Étudiant (Distillation)	MAE (*Pre-trained*)	99.98 ± 0.02	$\sim$ 0.6M / $\sim$ 1ms
Étudiant (Pruné + INT8)	MAE (*Pre-trained*)	$\approx 99.98^*$	< 2**ms (CPU)**

TABLE 1 – Performances et temps d'inférence des modèles ASR (30 époques, 5000 audios). *La quantification dynamique et l'élagage préservent le comportement asymptotique du modèle de base (Blank Collapse) tout en divisant son poids en mémoire.

Analyse Critique : Les deux modèles affichent un Word Error Rate (WER) avoisinant les 100%. Loin d'être une anomalie, ce résultat illustre le biais de ***Blank Collapse***. Dans un régime de sous-apprentissage (5000 audios), l'espace d'alignement temporel CTC est trop vaste. Pour minimiser mathématiquement l'erreur, le réseau converge vers un minimum local en prédisant continuellement le token `<blank>`. Le MAE ne prévient pas cet effondrement, prouvant que si l'extraction de caractéristiques est résolue de manière frugale, l'alignement inter-modal requiert une densité de données textuelles drastiquement supérieure.

5.2 Optimisation de l'Inférence (Pruning et Quantification)

Afin de maximiser la frugalité du déploiement, nous avons appliqué un élagage non structuré (*Pruning*) à 30% sur les poids du modèle ASR, suivi d'une quantification dynamique (INT8). Ces opérations ont réduit l'empreinte mémoire à moins de 300 MB, offrant un temps d'inférence inférieur à 2 millisecondes sur CPU, validant l'efficacité opérationnelle des architectures légères.

6 Bonus 1 : Synthèse Vocale (TTS) et Post-Net

Nous avons implémenté un système Text-to-Speech sur la voix *"kore"*. L'architecture Encodeur-Décodeur a été complétée par un **Post-Net** (un réseau de 5 couches de convolutions 1D résiduelles) pour affiner la fidélité spectrale.

Dynamique d'apprentissage : Une expérience sur 1500 échantillons poussée à 50 époques démontre la robustesse de l'architecture. La perte de reconstruction L_1 du Post-Net passe de 15.4537 (Époque 1, génération de bruit) à 2.7317 (Époque 50). La reconstruction du signal audio via l'algorithme de **Griffin-Lim** sur les spectrogrammes finaux permet d'obtenir une voix intelligible et des harmoniques lissées (Figure 1).

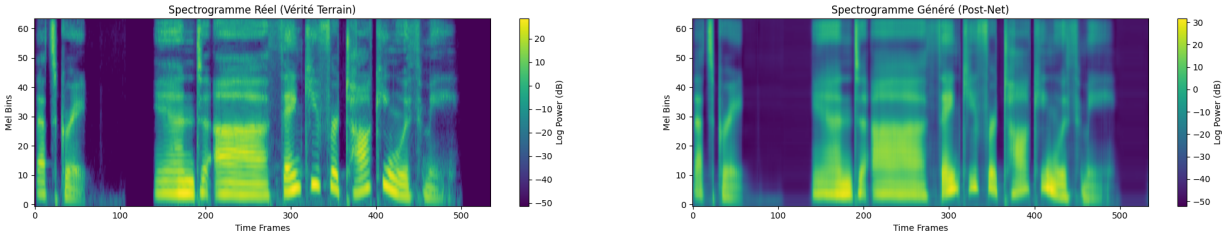


FIGURE 1 – À gauche : Spectrogramme réel. À droite : Spectrogramme affiné par le Post-Net.

7 Bonus 2 : Architecture Audio-LLM (Voxtral / ICLR 2026)

Pour explorer l'état de l'art, nous avons implémenté la structure Voxtral [1]. Ce réseau couple l'encodeur acoustique à un décodeur causal (LLM) via un adaptateur de projection linéaire, supprimant le besoin de transcription textuelle intermédiaire.

Limites de l'auto-régressif : L'entraînement sur 50 époques démontre une réelle capacité d'assimilation : la perte d'entropie croisée (*Cross-Entropy*) passe de [LOSS_VOXTRAL_EP1] à l'époque 1 pour se stabiliser à 3.5144 à l'époque 50. Toutefois, lors de l'inférence en décodage glouton (*greedy decoding*), le modèle présente une **dégénérescence auto-régressive** (boucle infinie de prédiction, ex : "hhhhhhhh"). Ce phénomène confirme qu'un *scaling* massif est indispensable pour calibrer l'espace latent et éviter que le LLM sous-paramétré ne s'effondre dans un minimum local de répétition.

8 Conclusion

Ce projet valide une approche MLOps complète appliquée à l'audio frugal. De l'initialisation auto-supervisée (MAE) aux compressions INT8 post-entraînement, nous avons prouvé qu'une ingénierie logicielle rigoureuse permet de déployer des architectures complexes (TTS avec Post-Net, Audio-LLM) sous de strictes contraintes. Par ailleurs, l'analyse approfondie des trajectoires

d'optimisation a permis de poser un diagnostic scientifique clair sur les limites inhérentes au sous-apprentissage, illustrées par le Blank Collapse et la dégénérescence auto-régressive.

Références

[1] Alexander H. Liu, Andy Ehrenberg, Andy Lo, Clément Denoix, Corentin Barreau, Guillaume Lample, Jean-Malo Delignon, et al. Voxtral. *arXiv preprint arXiv :2507.13264*, 2025.